

Perbandingan Performa XGBoost dan LightGBM dalam Prediksi Churn Pelanggan Netflix

Hilda Desfianty Arifin¹, Basuki Rahmat²

^{1,2} Informatika, Universitas Pembangunan Nasional “Veteran” Jawa Timur

¹22081010206@student.upnjatim.ac.id

*Corresponding author email: basukirahmat.if@upnjatim.ac.id

Abstrak— Persaingan layanan streaming over-the-top (OTT) menjadikan customer churn sebagai isu strategis yang berdampak langsung pada keberlanjutan bisnis. Penelitian ini membandingkan performa algoritma XGBoost dan LightGBM dalam memprediksi churn pelanggan Netflix menggunakan fitur perilaku pengguna. Dataset diproses melalui encoding, normalisasi, dan penanganan ketidakseimbangan kelas menggunakan Synthetic Minority Over-sampling Technique (SMOTE). Evaluasi dilakukan menggunakan metrik accuracy, precision, recall, F1-score, dan Area Under Curve (AUC). Hasil penelitian menunjukkan bahwa XGBoost memperoleh akurasi 99,07% dengan AUC 0,9982, sedangkan LightGBM memperoleh akurasi 98,80% dengan AUC 0,9989. Kedua model menunjukkan performa yang sangat baik dan relatif sebanding dalam prediksi churn pelanggan.

Kata Kunci— Churn, Netflix, XGBoost, LightGBM, SMOTE.

I. PENDAHULUAN

Perkembangan layanan hiburan digital berbasis platform streaming telah mengubah pola konsumsi media dari format konvensional menjadi on-demand dan personalisasi. Pergeseran ini mendorong meningkatnya persaingan antar platform over-the-top (OTT), sehingga customer churn atau keputusan pengguna untuk menghentikan langganan menjadi isu strategis yang berdampak langsung pada keberlanjutan bisnis [1]. Studi empiris menunjukkan bahwa churn pada layanan OTT dipengaruhi oleh pengalaman pengguna, kepuasan konten, serta perilaku menonton seperti durasi tontonan dan pola konsumsi konten [2].

Karakteristik utama domain streaming terletak pada data perilaku pengguna yang bersifat granular, mencakup watch-time, jeda antar episode, pola binge-watching, dan preferensi genre. Penelitian sebelumnya menunjukkan bahwa rekayasa fitur perilaku yang tepat mampu mereduksi kompleksitas data waktu nyata sekaligus meningkatkan kemampuan prediktif model churn [3]. Oleh karena itu, pemodelan churn pada platform streaming memerlukan pendekatan machine learning yang mampu menangani data berdimensi tinggi dan hubungan nonlinier antar fitur.

Dalam literatur prediksi churn, metode ensemble berbasis gradient boosting seperti XGBoost dan LightGBM terbukti memiliki performa yang kuat pada masalah klasifikasi biner dengan jumlah fitur besar [4]. Namun, performa model sangat

dipengaruhi oleh permasalahan ketidakseimbangan kelas, di mana jumlah pelanggan churn umumnya jauh lebih sedikit dibanding pelanggan aktif [5]. Penelitian Nugraha dan Syarif [6] menunjukkan bahwa penerapan teknik weighting pada algoritma XGBoost, LightGBM, dan CatBoost mampu meningkatkan sensitivitas model terhadap kelas minoritas tanpa perlu melakukan oversampling atau undersampling. Temuan ini menegaskan pentingnya strategi penanganan class imbalance dalam studi churn.

Penelitian Lalwani et al. [7] pada domain telekomunikasi juga menegaskan keunggulan algoritma ensemble seperti AdaBoost dan XGBoost dalam prediksi churn, dengan akurasi dan nilai AUC yang lebih tinggi dibanding model konvensional. Sementara itu, tinjauan sistematis oleh Manzoor et al. [8] mengungkap bahwa sebagian besar penelitian churn masih berfokus pada pengembangan model dan fitur, dengan keterbatasan pada konteks domain spesifik serta kurangnya perbandingan model yang komprehensif.


Selain pemilihan algoritma, optimasi hyperparameter menjadi faktor krusial dalam meningkatkan performa model boosting. Pendekatan Bayesian Optimization seperti Optuna terbukti lebih efisien dan adaptif dibanding GridSearch atau RandomSearch [9]. Studi terbaru yang mengombinasikan LightGBM dan Optuna menunjukkan peningkatan akurasi sekaligus efisiensi waktu pelatihan yang signifikan [10], sehingga relevan untuk memastikan perbandingan model dilakukan pada kondisi parameter optimal.

Meskipun demikian, terdapat celah penelitian karena masih terbatasnya studi open-access yang secara khusus membandingkan XGBoost dan LightGBM pada dataset churn platform streaming video, terutama yang berfokus pada fitur perilaku menonton seperti watch-time dan binge patterns. Sebagian besar penelitian sebelumnya berfokus pada domain telekomunikasi, perbankan, atau e-commerce, sehingga generalisasinya ke konteks video on-demand masih terbatas.

II. METODE PENELITIAN

Metode penelitian ini bertujuan untuk memberikan gambaran tentang langkah-langkah yang diambil dalam proses perbandingan XGBoost dan LightGBM untuk prediksi churn Netflix. Proses penelitian ini mencakup beberapa langkah seperti pengumpulan data, *preprocessing*, SMOTE, pembangunan model, hingga evaluasi model dengan

mengukur performa akurasi dan metrik lainnya seperti pada Gbr.1.



Gbr. 1 Alur Penelitian

A. Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan dataset sekunder yang diperoleh dari platform Kaggle, yaitu *Netflix Customer Churn Dataset*. Dataset ini berisi informasi pelanggan Netflix yang mencakup data demografis, jenis langganan, perilaku penggunaan layanan, serta status churn pelanggan. Data diunduh secara langsung menggunakan Kaggle API dan dimuat ke dalam lingkungan Python untuk proses analisis lebih lanjut. Variabel target dalam penelitian ini adalah churned, yang menunjukkan apakah pelanggan berhenti berlangganan atau tidak. Sementara itu, variabel independen mencakup atribut seperti usia pelanggan, durasi menonton, frekuensi login, jenis perangkat, metode pembayaran, dan preferensi genre.

B. Preprocessing

Tahap pra-pemrosesan data dilakukan untuk memastikan kualitas dan kesiapan data sebelum digunakan dalam proses pelatihan model. Pada tahap ini, kolom *customer_id* dihapus karena hanya berfungsi sebagai identitas pelanggan dan tidak berkontribusi terhadap proses prediksi churn. Selanjutnya, data dipisahkan menjadi variabel target dan variabel fitur. Fitur kategorikal seperti *gender*, *subscription_type*, *region*, *device*, *payment_method*, dan *favorite_genre* diubah ke dalam bentuk numerik menggunakan metode *Label Encoding*. Sementara itu, fitur numerik seperti *age*, *watch_hours*, *last_login_days*, *monthly_fee*, *number_of_profiles*, dan *avg_watch_time_per_day* dinormalisasi menggunakan metode *Min-Max Scaling* agar seluruh fitur berada pada rentang nilai yang seragam dan tidak saling mendominasi dalam proses pembelajaran model. Dataset kemudian dibagi menjadi data latih dan data uji dengan proporsi 85% untuk data latih dan 15% untuk data uji menggunakan teknik *stratified split* guna menjaga distribusi kelas churn dan non-churn tetap seimbang.

C. SMOTE

Permasalahan ketidakseimbangan kelas merupakan karakteristik umum pada dataset churn, di mana jumlah pelanggan yang tidak churn lebih banyak dibandingkan pelanggan yang churn. Untuk mengatasi permasalahan tersebut, penelitian ini menerapkan metode *Synthetic Minority Over-sampling Technique* (SMOTE) pada data latih. SMOTE bekerja dengan menghasilkan data sintetis pada kelas

minoritas berdasarkan kedekatan antar data, sehingga distribusi kelas menjadi lebih seimbang. Proses SMOTE hanya diterapkan pada data latih untuk menghindari terjadinya *data leakage* dan menggunakan nilai *random_state* sebesar 42 agar hasil eksperimen dapat direproduksi.

D. Pembangunan Model

Pada tahap pembangunan model, penelitian ini menggunakan dua algoritma ensemble berbasis gradient boosting, yaitu XGBoost dan LightGBM. Model XGBoost dibangun dengan parameter utama berupa *n_estimators* sebesar 150, *learning_rate* sebesar 0,1, *max_depth* sebesar 6, serta nilai *subsample* dan *colsample_bytree* masing-masing sebesar 0,8. Model ini menggunakan fungsi objektif *binary logistic* untuk menangani permasalahan klasifikasi biner churn dan dilatih menggunakan data latih hasil SMOTE. Model LightGBM dibangun dengan konfigurasi parameter yang sebanding, yaitu *n_estimators* sebesar 150, *learning_rate* sebesar 0,1, *max_depth* sebesar 6, serta nilai *subsample* dan *colsample_bytree* sebesar 0,8. Model LightGBM juga dilatih menggunakan data latih yang telah diseimbangkan dengan SMOTE, sehingga perbandingan performa antara kedua model dapat dilakukan secara adil dan konsisten.

E. Evaluasi Model

valuasi performa model dilakukan menggunakan data uji yang tidak terlibat dalam proses pelatihan. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan *Area Under the Curve* (AUC) untuk menilai kemampuan model dalam mengklasifikasikan pelanggan churn dan tidak churn. Selain itu, evaluasi juga dilakukan menggunakan *confusion matrix* untuk menganalisis kesalahan klasifikasi yang dihasilkan oleh masing-masing model. Hasil evaluasi dari model XGBoost dan LightGBM kemudian dibandingkan untuk menentukan model yang memiliki performa terbaik dalam memprediksi churn pelanggan Netflix.

III. HASIL DAN PEMBAHASAN

Penelitian ini mengevaluasi performa dua algoritma ensemble berbasis gradient boosting, yaitu XGBoost dan LightGBM, dalam memprediksi customer churn pada layanan streaming Netflix. Evaluasi dilakukan menggunakan data uji yang tidak terlibat dalam proses pelatihan model. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan *Area Under Curve* (AUC), serta analisis *confusion matrix* untuk melihat distribusi kesalahan klasifikasi secara lebih rinci. Hasil pengujian menunjukkan bahwa kedua model mampu menghasilkan performa klasifikasi yang sangat baik, dengan nilai akurasi di atas 98%. Hal ini mengindikasikan bahwa fitur perilaku pelanggan yang digunakan, serta penerapan SMOTE dalam menangani ketidakseimbangan kelas, mampu mendukung model dalam mempelajari pola churn secara efektif.


A. Hasil Evaluasi Model XGBoost

Berdasarkan hasil pengujian, model XGBoost memperoleh nilai akurasi sebesar 99,07%, yang menunjukkan bahwa sebagian besar data uji berhasil diklasifikasikan dengan benar. Untuk kelas *Tidak Churn*, model menghasilkan nilai precision sebesar 0,9867 dan recall sebesar 0,9946, sedangkan untuk kelas *Churn* diperoleh precision sebesar 0,9947 dan recall sebesar 0,9867. Nilai F1-score untuk kedua kelas berada di kisaran 0,99, yang menunjukkan keseimbangan yang sangat baik antara precision dan recall.

	precision	recall	f1-score	support
Tidak Churn	0.986702	0.994638	0.990654	373.000000
Churn	0.994652	0.986737	0.990679	377.000000
accuracy	0.990667	0.990667	0.990667	0.990667
macro avg	0.990677	0.990688	0.990667	750.000000
weighted avg	0.990698	0.990667	0.990667	750.000000

Gbr. 2 Classification Report XGBoost

Nilai AUC yang diperoleh model XGBoost sebesar 0,9982, menandakan kemampuan model yang sangat kuat dalam membedakan pelanggan churn dan tidak churn pada berbagai nilai ambang klasifikasi. Analisis confusion matrix menunjukkan bahwa sebagian besar prediksi berada pada diagonal utama, yang berarti model mampu meminimalkan kesalahan klasifikasi baik false positive maupun false negative. Namun demikian, masih terdapat sejumlah kecil pelanggan churn yang diprediksi sebagai tidak churn, yang menjadi area potensial untuk peningkatan sensitivitas model.



Gbr. 3 Confusion Matrix XGBoost

B. Hasil Evaluasi Model LightGBM


Model LightGBM juga menunjukkan performa yang sangat baik dalam memprediksi customer churn. Hasil evaluasi menunjukkan bahwa LightGBM memperoleh nilai akurasi

sebesar 98,80%. Untuk kelas *Tidak Churn*, nilai precision dan recall masing-masing sebesar 0,9840 dan 0,9920, sedangkan untuk kelas *Churn* diperoleh nilai precision sebesar 0,9920 dan recall sebesar 0,9841. Nilai F1-score untuk kedua kelas berada di sekitar 0,988, yang mengindikasikan konsistensi performa model dalam mengklasifikasikan kedua kelas.

	precision	recall	f1-score	support
Tidak Churn	0.984043	0.991957	0.987984	373.000
Churn	0.991979	0.984085	0.988016	377.000
accuracy	0.988000	0.988000	0.988000	0.988
macro avg	0.988011	0.988021	0.988000	750.000
weighted avg	0.988032	0.988000	0.988000	750.000

Gbr. 4 Classification Report LighGBM

Nilai AUC yang dihasilkan LightGBM sebesar 0,9989, sedikit lebih tinggi dibandingkan XGBoost, yang menunjukkan bahwa LightGBM memiliki kemampuan diskriminatif yang sangat baik. Confusion matrix menunjukkan pola kesalahan klasifikasi yang serupa dengan XGBoost, di mana sebagian besar data berhasil diklasifikasikan dengan benar, namun masih terdapat sejumlah kecil kesalahan pada kelas churn.



Gbr. 5 Confusion Matrix LightGBM

C. Perbandingan Model XGBoost dan LightGBM

Perbandingan performa kedua model menunjukkan bahwa XGBoost memiliki nilai akurasi (99,07%) dan F1-score (0,9907) yang sedikit lebih tinggi dibandingkan LightGBM, yang memperoleh akurasi (98,80%) dan F1-score (0,9880). Dari sisi precision dan recall, kedua model menunjukkan nilai yang sangat berdekatan, dengan XGBoost sedikit lebih unggul dalam mendeteksi pelanggan churn berdasarkan nilai recall (0,9867) dibandingkan LightGBM (0,9841). Sebaliknya, LightGBM menghasilkan nilai AUC yang sedikit lebih tinggi (0,9989) dibandingkan XGBoost (0,9982), yang menunjukkan keunggulan LightGBM dalam membedakan kelas churn dan

tidak churn secara probabilistik. Secara keseluruhan, perbedaan performa kedua model tidak signifikan, sehingga keduanya dapat dikategorikan sebagai model yang sangat efektif untuk prediksi churn pelanggan Netflix.

Model	Accuracy	Precision	Recall	F1-Score	AUC
XGBoost	0.990667	0.994652	0.986737	0.990679	0.998194
LightGBM	0.988000	0.991979	0.984085	0.988016	0.998919

Gbr. 6 Hasil Perbandingan XGBoost dan LightGBM

Hasil penelitian ini menunjukkan bahwa algoritma ensemble berbasis gradient boosting sangat efektif dalam menangani permasalahan prediksi churn pelanggan pada layanan streaming. Penerapan SMOTE terbukti mampu menyeimbangkan distribusi kelas sehingga model dapat mempelajari karakteristik pelanggan churn dengan lebih baik, yang tercermin dari nilai recall yang tinggi pada kedua model. Perbandingan antara XGBoost dan LightGBM menunjukkan bahwa XGBoost sedikit lebih unggul dalam hal akurasi dan keseimbangan metrik klasifikasi, sementara LightGBM memiliki keunggulan dalam nilai AUC serta dikenal lebih efisien dari sisi komputasi. Oleh karena itu, pemilihan model terbaik dapat disesuaikan dengan kebutuhan implementasi, apakah lebih mengutamakan akurasi prediksi atau efisiensi sistem. Secara keseluruhan, hasil penelitian ini mendukung penggunaan XGBoost dan LightGBM sebagai pendekatan yang andal dalam mendukung strategi retensi pelanggan berbasis data pada industri streaming digital.

IV. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa algoritma ensemble berbasis gradient boosting, yaitu XGBoost dan LightGBM, mampu memberikan performa yang sangat baik dalam memprediksi customer churn pada layanan streaming Netflix. Tahapan pra-pemrosesan data, termasuk encoding fitur kategorikal, normalisasi fitur numerik, serta penanganan ketidakseimbangan kelas menggunakan SMOTE, terbukti berperan penting dalam meningkatkan kemampuan model dalam mendeteksi pelanggan churn. Hasil evaluasi menunjukkan bahwa XGBoost memperoleh akurasi sebesar 99,07% dengan nilai AUC 0,9982, sedangkan LightGBM memperoleh akurasi sebesar 98,80% dengan nilai AUC 0,9989, yang mengindikasikan bahwa kedua model memiliki

performa klasifikasi yang sangat tinggi dan relatif sebanding. XGBoost menunjukkan keunggulan tipis pada metrik akurasi dan F1-score, sementara LightGBM unggul pada nilai AUC serta memiliki efisiensi komputasi yang lebih baik. Oleh karena itu, pemilihan model dapat disesuaikan dengan kebutuhan implementasi, baik yang berfokus pada akurasi prediksi maupun efisiensi sistem. Untuk penelitian selanjutnya, disarankan untuk menambahkan fitur perilaku yang lebih kompleks dan bersifat temporal, menerapkan optimasi hyperparameter berbasis Bayesian Optimization secara lebih mendalam, serta menggunakan metrik evaluasi berbasis profitabilitas dan pendekatan explainable AI guna meningkatkan relevansi bisnis dan interpretabilitas model.

REFERENSI

- [1] "The Evolution and Impact of Streaming Services: Changing the Media Landscape," *Arch. Med.*, 2024.
- [2] A. Jadhav and M. Mohan, "Predicting Customer Churn on OTT Platforms: Customers with Subscription of Multiple Service Providers," *J. Inf. Organ. Sci.*, vol. 46, no. 2, pp. 433–451, Dec. 2022, doi: 10.31341/jios.46.2.10.
- [3] R. A. Moral et al., "Profiling Television Watching Behavior Using Bayesian Hierarchical Joint Models for Time-to-Event and Count Data," *IEEE Access*, vol. 10, pp. 113018–113027, 2022, doi:10.1109/ACCESS.2022.3215682.
- [4] M. Bogaert and L. Delaere, "Ensemble Methods in Customer Churn Prediction: A Comparative Analysis of the State-of-the-Art," *Mathematics*, vol. 11, no. 5, p. 1137, Feb. 2023, doi: 10.3390/math11051137.
- [5] R. Suguna, J. Suriya Prakash, H. Aditya Pai, T. R. Mahesh, V. Vinod Kumar, and T. E. Yimer, "Mitigating class imbalance in churn prediction with ensemble methods and SMOTE," *Sci. Rep.*, vol. 15, no. 1, p. 16256, May 2025, doi: 10.1038/s41598-025-01031-0.
- [6] W. Nugraha and M. Syarif, "Teknik Weighting untuk Mengatasi Ketidakseimbangan Kelas Pada Prediksi Churn Menggunakan XGBoost, LightGBM, dan CatBoost," *Techno.Com*, vol. 22, no. 1, pp. 97–108, Feb. 2023, doi: 10.33633/tc.v22i1.7191.
- [7] P. Lalwani, M. K. Mishra, J. S. Chadha, and P. Sethi, "Customer churn prediction system: a machine learning approach," *Computing*, vol. 104, no. 2, pp. 271–294, Feb. 2022, doi: 10.1007/s00607-021-00908-y.
- [8] A. Manzoor, M. Atif Qureshi, E. Kidney, and L. Longo, "A Review on Machine Learning Methods for Customer Churn Prediction and Recommendations for Business Practitioners," *IEEE Access*, vol. 12, pp. 70434–70463, 2024, doi: 10.1109/ACCESS.2024.3402092.
- [9] Y. Cai, J. Feng, Y. Wang, Y. Ding, Y. Hu, and H. Fang, "The Optuna LightGBM–XGBoost Model: A Novel Approach for Estimating Carbon Emissions Based on the Electricity–Carbon Nexus," *Appl. Sci.*, vol. 14, no. 11, p. 4632, May 2024, doi: 10.3390/app14114632.
- [10] R. J. Wishnuwardana, M. B. Omar, H. B. Zabiri, M. Faqih, K. Bingi, and R. Ibrahim, "Optuna-LightGBM: An Optuna hyperparameter optimization framework for the determination of solvent components in acid gas removal unit using LightGBM," *Clean. Eng. Technol.*, vol. 28, p. 101054, Sep. 2025, doi: 10.1016/j.clet.2025.101054.